ANALISIS KOMPARATIF ALGORITMA MACHINE LEARNING UNTUK SISTEM PENILAIAN KREDIT KONSUMER DI INDONESIA

Studi Komparatif Logistic Regression, Random Forest, dan XGBoost

Ade Saputra

2026

Eksperimen berbasis data sintetik 10.000 nasabah dengan 36 fitur demografis, keuangan, dan riwayat kredit dalam konteks perbankan Indonesia

Abstrak

Penelitian ini bertujuan membandingkan kinerja tiga algoritma machine learning, yaitu Logistic Regression, Random Forest, dan XGBoost, dalam sistem penilaian kredit konsumer di Indonesia. Studi ini menggunakan dataset sintetik berjumlah 10.000 observasi yang mencerminkan karakteristik demografis, finansial, dan riwayat kredit nasabah Indonesia. Metodologi penelitian meliputi tahap pra-pemrosesan data, pelatihan model, dan evaluasi menggunakan metrik akurasi, precision, recall, dan F1-score. Hasil penelitian menunjukkan bahwa model XGBoost memberikan performa terbaik dengan nilai akurasi sebesar 0,9085 dan F1-Macro sebesar 0,8907, diikuti oleh Logistic Regression dengan akurasi 0,9085 dan F1-Macro 0,8851, serta Random Forest dengan akurasi 0,9080 dan F1-Macro 0,8813. Temuan ini menunjukkan bahwa algoritma ensemble berbasis gradient boosting lebih efektif dalam menangani kompleksitas data kredit dibandingkan model linear maupun bagging. Penelitian ini berkontribusi dalam pengembangan sistem penilaian kredit berbasis data untuk meningkatkan kualitas pengambilan keputusan di sektor keuangan.

Kata Kunci: *credit scoring, machine learning, XGBoost, random forest, logistic regression, penilaian kredit, klasifikasi multiclass*

1 Pendahuluan

1.1 Latar Belakang

Penilaian kredit (*credit scoring*) merupakan komponen fundamental dalam sistem keuangan modern. Proses ini berfungsi sebagai mekanisme evaluasi statistik yang digunakan lembaga keuangan untuk menilai kelayakan kredit calon debitur dan mengukur probabilitas gagal bayar. Dalam ekosistem perbankan Indonesia, risiko kredit bermasalah yang tercermin dalam rasio Non-Performing Loan (NPL)

menjadi tantangan signifikan yang secara langsung memengaruhi profitabilitas dan stabilitas institusi keuangan.

Otoritas Jasa Keuangan (OJK) sebagai regulator sektor keuangan di Indonesia mengklasifikasikan kualitas kredit ke dalam lima kategori, mulai dari Lancar hingga Macet. Peningkatan volume kredit konsumer di Indonesia, yang didorong oleh pertumbuhan ekonomi digital dan inklusi keuangan, menuntut metode evaluasi risiko yang lebih akurat, cepat, dan objektif. Metode tradisional yang berbasis statistik klasik, seperti analisis diskriminan dan regresi logistik konvensional, sering menghadapi keterbatasan dalam menangkap pola kompleks dan hubungan nonlinier pada data keuangan nasabah yang semakin beragam.
Seiring perkembangan teknologi kecerdasan buatan, pendekatan machine learning mulai banyak diadopsi dalam sistem penilaian kredit karena kemampuannya yang unggul dalam memodelkan hubungan nonlinier, menangani dataset berdimensi tinggi, dan mengekstraksi pola tersembunyi dari data. Berbagai algoritma telah diterapkan dalam domain ini, termasuk Logistic Regression sebagai baseline klasik, Random Forest sebagai representasi metode ensemble berbasis bagging, dan XGBoost sebagai state-of-the-art dalam gradient boosting untuk data tabular.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini merumuskan permasalahan sebagai berikut: bagaimana perbandingan kinerja algoritma Logistic Regression, Random Forest, dan XGBoost dalam memprediksi kualitas kredit nasabah pada konteks perbankan Indonesia? Algoritma manakah yang memberikan performa optimal berdasarkan metrik evaluasi klasifikasi multiclass?

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk: (1) membandingkan performa tiga algoritma machine learning dalam klasifikasi risiko kredit tiga kelas (Lancar, Perhatian, Macet); (2) mengidentifikasi model dengan akurasi dan F1-score terbaik untuk implementasi praktis; serta (3) menganalisis fitur-fitur yang paling berpengaruh dalam prediksi risiko kredit melalui analisis feature importance.

1.4 Manfaat Penelitian

Secara teoretis, penelitian ini berkontribusi dalam memperkaya literatur komparatif algoritma machine learning untuk permasalahan credit scoring dalam konteks negara berkembang. Secara praktis, temuan penelitian ini dapat menjadi acuan bagi lembaga keuangan di Indonesia dalam memilih algoritma yang tepat

untuk sistem penilaian kredit otomatis, serta memberikan insight mengenai faktor-faktor finansial yang paling prediktif terhadap risiko kredit.

2 Tinjauan Pustaka

2.1 Credit Scoring dan Klasifikasi Risiko Kredit

Credit scoring adalah proses kuantitatif yang menggunakan model statistik atau algoritmik untuk menghasilkan skor numerik yang merepresentasikan tingkat risiko kredit seorang debitur. Dalam praktik perbankan Indonesia, OJK menerapkan klasifikasi kualitas kredit berdasarkan kolektibilitas. Untuk keperluan penelitian ini, klasifikasi disederhanakan menjadi tiga kelas sesuai tingkat risiko yang dirangkum dalam Tabel 1.

Tabel 1. Klasifikasi Kualitas Kredit dalam Penelitian

Kelas	Deskripsi	Distribusi	Kode
Lancar	Pembayaran tepat waktu, tidak ada tunggakan signifikan	55,7%	0
Perhatian	Tunggakan 1-90 hari, memerlukan pemantauan intensif	34,7%	1
Macet	Tunggakan >90 hari, risiko gagal bayar tinggi	9,5%	2

2.2 Logistic Regression

Logistic Regression merupakan model klasifikasi linear yang memodelkan probabilitas kelas target sebagai fungsi logistik dari kombinasi linear fitur-fitur input. Dalam konteks klasifikasi multiclass, digunakan pendekatan one-vs-rest (OvR) atau softmax regression. Kelebihan utama Logistic Regression terletak pada interpretabilitasnya yang tinggi dan efisiensi komputasi. Namun, model ini memiliki asumsi linearitas antara fitur dan log-odds, yang membatasi kemampuannya dalam menangkap hubungan nonlinier yang kompleks. Logistic Regression juga sensitif terhadap skala fitur, sehingga memerlukan proses standardisasi sebelum pelatihan.

2.3 Random Forest

Random Forest merupakan algoritma ensemble berbasis bagging yang menggabungkan sejumlah besar pohon keputusan (decision tree) yang dilatih secara independen pada subset acak dari data dan fitur. Prediksi akhir ditentukan melalui mekanisme majority voting (untuk klasifikasi). Kelebihan Random Forest mencakup robustness terhadap noise, kemampuan menangani fitur campuran (numerik dan kategorikal), serta ketahanan terhadap overfitting berkat mekanisme aggregation. Model ini tidak memerlukan scaling fitur karena

berbasis pohon keputusan. Dalam penelitian ini, Random Forest dikonfigurasi dengan 200 estimator dan kedalaman maksimum 8.

2.4 XGBoost (Extreme Gradient Boosting)

XGBoost (eXtreme Gradient Boosting) merupakan implementasi gradient boosting yang dioptimasi untuk kecepatan dan performa. Berbeda dengan Random Forest yang melatih pohon secara independen, XGBoost melatih pohon secara sekuensial, di mana setiap pohon baru difokuskan untuk memperbaiki kesalahan prediksi pohon-pohon sebelumnya. XGBoost memiliki beberapa keunggulan teknis, antara lain: regularisasi L1 dan L2 bawaan untuk mencegah overfitting, mekanisme early stopping untuk menghentikan pelatihan saat performa validasi tidak meningkat, serta efisiensi komputasi melalui paralelisasi dan optimasi cache. Dalam penelitian ini, XGBoost dikonfigurasi dengan maksimum 500 pohon, learning rate 0,05, dan early stopping pada 20 iterasi tanpa perbaikan.

3 Metodologi Penelitian

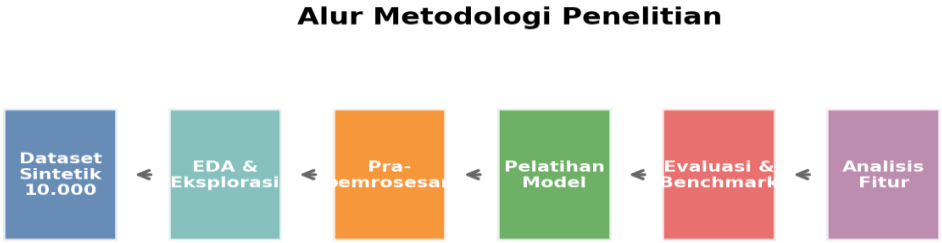

Gambar 1. Diagram alur metodologi penelitian

3.1 Dataset dan Variabel Penelitian

Penelitian ini menggunakan dataset sintetik yang dihasilkan secara algoritmik dengan distribusi statistik yang merepresentasikan karakteristik kredit nasabah di Indonesia. Dataset terdiri dari 10.000 observasi dengan 36 fitur prediktor dan 1 variabel target (status kredit). Penggunaan data sintetik didasari oleh keterbatasan akses terhadap data kredit riil yang bersifat rahasia dan dilindungi regulasi. Namun demikian, distribusi parameter data sintetik dirancang untuk mencerminkan pola-pola yang lazim ditemukan dalam data kredit perbankan Indonesia.

Dataset mencakup 23 fitur numerik dan 13 fitur kategorikal yang dibagi ke dalam tiga kelompok utama:

Fitur Demografis: usia nasabah (rentang 21-65 tahun), jenis kelamin, status pernikahan, jumlah tanggungan, jumlah anak, tingkat pendidikan (SMA, Diploma, S1, S2), serta lokasi tempat tinggal (urban/rural).

Fitur Finansial: penghasilan bulanan (rata-rata Rp 6,68 juta), penghasilan tambahan, penghasilan pasangan, total penghasilan, angsuran bulanan, debt-to-income ratio (DTI), loan-to-income ratio (LTI), saldo tabungan, nilai aset, dan rasio aset terhadap utang.
Fitur Riwayat Kredit: jumlah kredit sebelumnya, jumlah tunggakan, hari tunggakan terlama, riwayat kredit (Baik/Cukup/Buruk), serta variabel terkait pekerjaan (lama bekerja, sektor pekerjaan, level pekerjaan, risiko pekerjaan).

Tabel 2. Ringkasan Variabel Penelitian

Variabel	Tipe	Rentang/Kategori	Deskripsi
Penghasilan Bulanan	Numerik	Rp 2 jt - 15 jt	Pendapatan utama
DTI Ratio	Numerik	0,005 - 1,5	Rasio utang/pendapatan
LTI Ratio	Numerik	0,35 - 43,2	Rasio pinjaman/pendapatan
Hari Tunggakan	Numerik	0 - 365	Maks hari keterlambatan
Riwayat Kredit	Kategorikal	Baik/Cukup/Buruk	Rekam jejak pembayaran
Status Rumah	Kategorikal	Milik/KPR/Kontrak	Kepemilikan tempat tinggal
Status Kredit	Target	Lancar/Perhatian/Macet	Variabel dependen

3.2 Eksplorasi Data (EDA)

Tahap eksplorasi data bertujuan memahami struktur, distribusi, dan pola-pola dalam dataset sebelum proses pemodelan. Analisis deskriptif menunjukkan bahwa dataset bersih tanpa missing values dengan total penggunaan memori sebesar 9.226,9 KB. Dataset terdiri dari 14 kolom bertipe object (kategorikal), 13 kolom float64, dan 10 kolom int64.
Distribusi kelas target menunjukkan ketidakseimbangan (imbalanced), dengan kelas Lancar mendominasi sebesar 55,7% (5.573 nasabah), diikuti Perhatian 34,7% (3.473 nasabah), dan Macet sebagai kelas minoritas dengan 9,5% (954 nasabah). Ketidakseimbangan ini merepresentasikan kondisi realistis di mana mayoritas debitur membayar tepat waktu, sebagaimana Gambar 2 berikut.

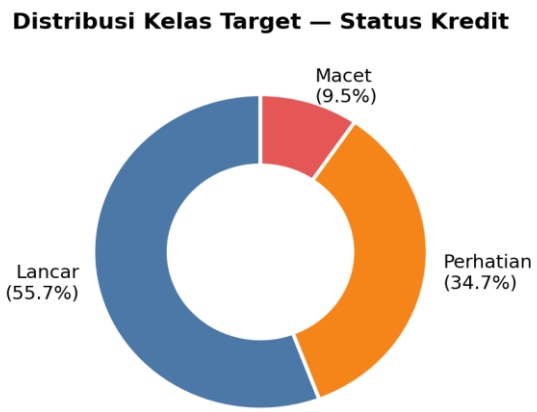

Gambar 2. Distribusi kelas target status kredit

Analisis korelasi antar fitur numerik kunci menggunakan heatmap (Gambar 3) mengungkapkan beberapa hubungan penting. Terdapat korelasi positif kuat antara DTI Ratio dengan variabel-variabel terkait tunggakan, yang mengindikasikan bahwa nasabah dengan beban utang tinggi cenderung mengalami keterlambatan pembayaran. Sebaliknya, Saldo Tabungan dan Penghasilan menunjukkan korelasi negatif dengan indikator risiko kredit.

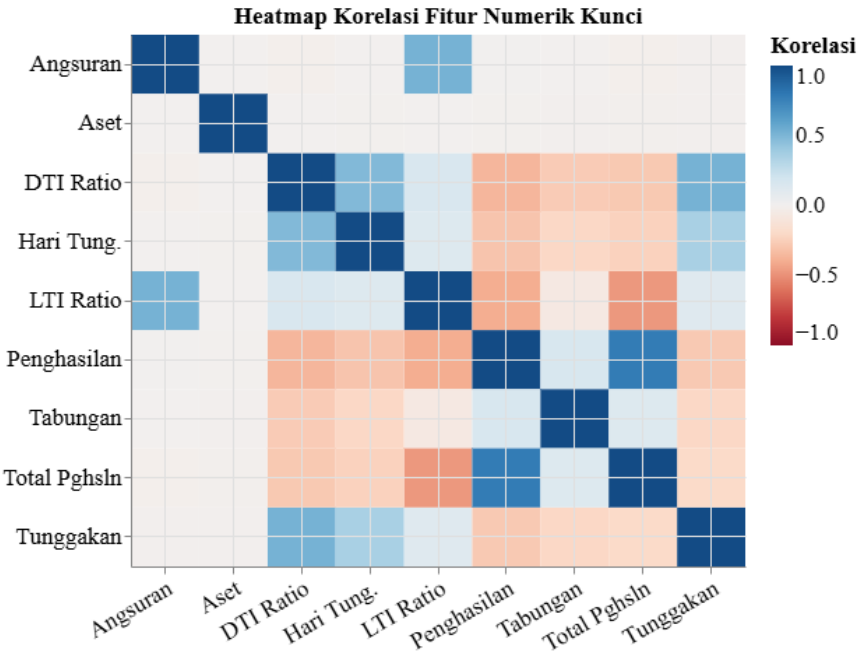

Gambar 3. Heatmap korelasi fitur numerik kunci

Analisis distribusi DTI Ratio per kelas kredit melalui boxplot (Gambar 4) menunjukkan perbedaan yang sangat jelas. Nasabah dengan status Lancar memiliki median DTI sekitar 0,15, nasabah Perhatian sekitar 0,30, sedangkan nasabah Macet memiliki median DTI di atas 0,55. Temuan ini mengonfirmasi bahwa rasio utang terhadap pendapatan merupakan indikator yang sangat diskriminatif untuk klasifikasi risiko kredit.

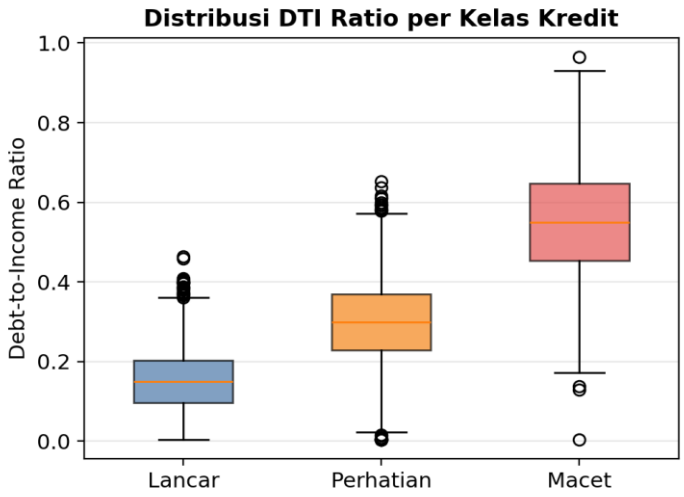

Gambar 4. Distribusi Debt-to-Income Ratio per kelas kredit

Distribusi riwayat kredit per status kredit (Gambar 5) menunjukkan pola yang intuitif: nasabah dengan riwayat kredit Baik secara dominan berada di kelas Lancar, sementara nasabah dengan riwayat Buruk lebih banyak berada di kelas Macet dan Perhatian. Pola ini mengindikasikan konsistensi dataset sintetik dengan logika bisnis perbankan.

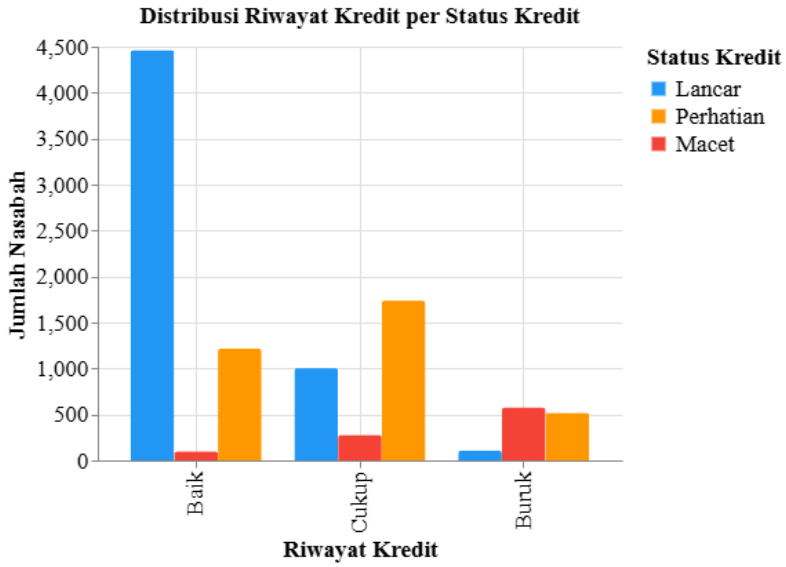

Gambar 5. Distribusi riwayat kredit per status kredit

3.3 Pra-pemrosesan Data

Tahap pra-pemrosesan data dirancang secara minimal namun tepat sasaran, mengingat bahwa dua dari tiga model yang digunakan (Random Forest dan XGBoost) berbasis pohon keputusan yang tidak memerlukan scaling fitur. Proses pra-pemrosesan meliputi tiga langkah utama:

Pertama, encoding fitur kategorikal menggunakan LabelEncoder dari scikit-learn untuk mengonversi 13 fitur kategorikal menjadi representasi integer. Pemilihan LabelEncoder (bukan One-Hot Encoding) didasarkan pada pertimbangan bahwa

model berbasis pohon keputusan dapat menangani encoding ordinal secara efektif.

Kedua, encoding variabel target status kredit menjadi representasi integer (Lancar=0, Macet=1, Perhatian=2) menggunakan LabelEncoder terpisah.

Ketiga, pembagian data menjadi training set (80%) dan test set (20%) menggunakan stratified split untuk mempertahankan proporsi kelas target pada kedua subset. Hasil split menghasilkan 8.000 sampel training dan 2.000 sampel test, dengan distribusi kelas yang proporsional pada kedua subset sebagaimana ditunjukkan pada Gambar 6.

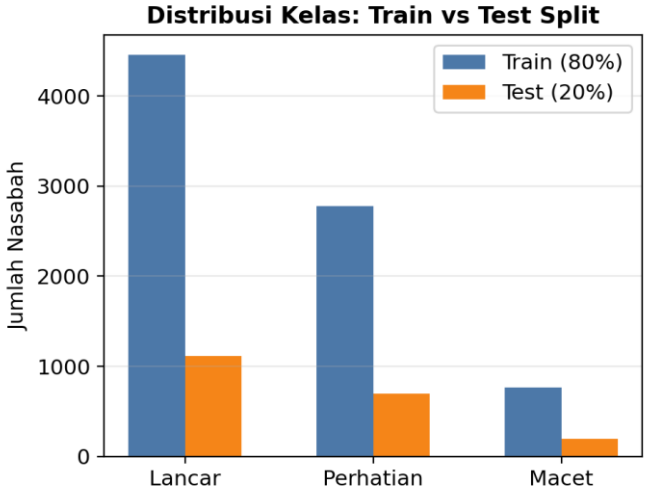

Gambar 6. Distribusi kelas pada train set dan test set (stratified 80/20)

Khusus untuk Logistic Regression, diterapkan StandardScaler untuk menormalisasi fitur numerik ke distribusi dengan mean=0 dan standar deviasi=1. Scaling ini hanya diterapkan pada data yang dimasukkan ke model Logistic Regression, sementara Random Forest dan XGBoost menggunakan data tanpa scaling.

3.4 Konfigurasi dan Pelatihan Model

Tiga model dilatih dan dievaluasi dengan konfigurasi yang dirangkum dalam Tabel 3. Setiap model dikonfigurasi dengan parameter yang umum digunakan dalam praktik machine learning untuk permasalahan klasifikasi tabular.

Tabel 3. Konfigurasi Parameter Model

Model	Parameter Kunci	Catatan
Logistic Regression	max_iter=1000, solver=lbfgs, multi_class=auto	Menggunakan StandardScaler; baseline klasik
Random Forest	n_estimators=200, max_depth=8, n_jobs=-1	Ensemble bagging; tanpa scaling
XGBoost	n_estimators=500, max_depth=6, lr=0.05, subsample=0.8, colsample_bytree=0.8,	Gradient boosting; regularisasi L1/L2; early stopping berdasarkan mlogloss

	reg_alpha=0.1, reg_lambda=1.0, early_stopping=20	

Pelatihan XGBoost menggunakan mekanisme early stopping dengan parameter patience sebesar 20 iterasi. Model berhenti pada iterasi ke-172 dari maksimum 500, dengan nilai best validation mlogloss sebesar 0,24000. Hal ini menunjukkan bahwa model mencapai performa optimal jauh sebelum batas maksimum iterasi, mengindikasikan efektivitas regularisasi bawaan XGBoost.

3.5 Metrik Evaluasi

Evaluasi model menggunakan empat metrik utama yang dihitung pada test set (2.000 sampel). Mengingat masalah klasifikasi multiclass dengan distribusi kelas tidak seimbang, digunakan varian macro-averaged untuk precision, recall, dan F1-score. Metrik macro-averaged menghitung rata-rata metrik dari setiap kelas secara independen, memberikan bobot yang sama pada setiap kelas tanpa memandang ukurannya. Pendekatan ini penting untuk memastikan bahwa performa pada kelas minoritas (Macet) tidak tertutupi oleh kelas mayoritas (Lancar).

4 Hasil dan Pembahasan

4.1 Perbandingan Performa Model (Benchmarking)

Hasil evaluasi ketiga model pada test set dirangkum dalam Tabel 4. Secara keseluruhan, ketiga model menunjukkan performa yang kompetitif dengan perbedaan yang relatif kecil antar model, yang mengindikasikan bahwa dataset memiliki pola yang cukup jelas untuk dipelajari oleh berbagai tipe algoritma.

Model	Accuracy	F1-Macro	Precision	Recall
Logistic Regression	0,9085	0,8851	0,9020	0,8706
Random Forest	0,9080	0,8813	0,9146	0,8566
XGBoost	**0,9085**	**0,8907**	**0,9069**	**0,8768**

Tabel 4. Hasil Evaluasi Performa Model pada Test Set (n=2.000)

Visualisasi perbandingan performa melalui grouped bar chart (Gambar 7) menunjukkan bahwa XGBoost memperoleh nilai tertinggi pada metrik Accuracy, F1-Macro, dan Recall-Macro, sementara Random Forest justru unggul pada Precision-Macro (0,9146). Meskipun selisih akurasi antara XGBoost dan Logistic Regression sangat kecil (keduanya
0,9085), XGBoost menunjukkan keunggulan yang lebih terlihat pada metrik F1-Macro (0,8907 vs 0,8851) dan Recall-Macro (0,8768 vs 0,8706). Namun, pada Precision-Macro, Random Forest justru memperoleh skor tertinggi (0,9146), diikuti XGBoost (0,9069) dan Logistic Regression (0,9020). Hal ini mengindikasikan bahwa Random Forest lebih konservatif dalam memberikan

prediksi positif, sementara XGBoost lebih unggul dalam mendeteksi seluruh kasus berisiko secara menyeluruh.

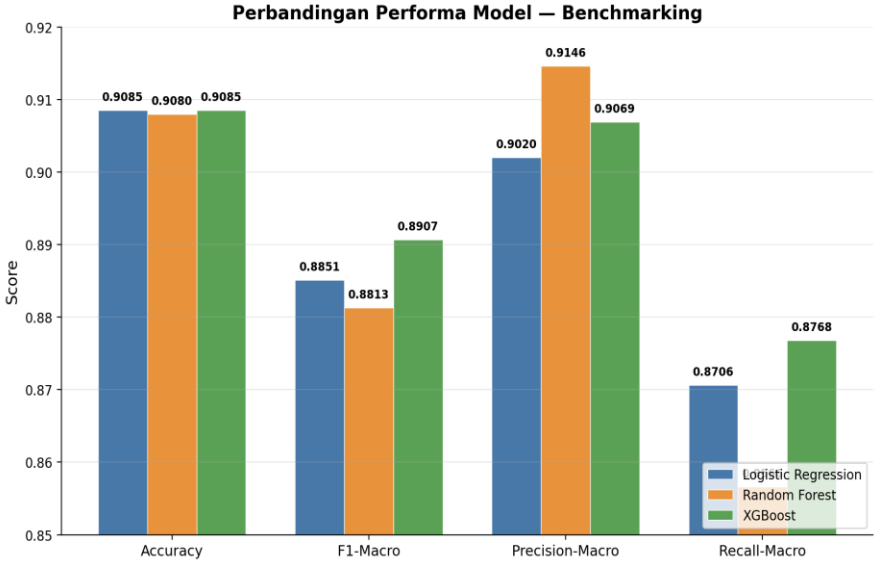

Gambar 7. Perbandingan performa tiga model berdasarkan metrik evaluasi

Ditinjau dari waktu pelatihan, Logistic Regression merupakan model tercepat (0,3 detik), diikuti Random Forest (3,4 detik), dan XGBoost (3,6 detik). Meskipun XGBoost memiliki waktu pelatihan sedikit lebih lama, mekanisme early stopping berhasil menghentikan training pada iterasi ke-172 dari 500 iterasi maksimum, menunjukkan efisiensi proses learning.

4.2 Evaluasi Detail Model Terbaik (XGBoost)

Confusion matrix XGBoost (Gambar 8) memberikan gambaran detail mengenai pola prediksi model pada setiap kelas. Model menunjukkan performa sangat baik pada kelas Lancar dengan mayoritas prediksi benar. Kelas Macet, meskipun merupakan kelas minoritas, juga diprediksi dengan akurasi tinggi. Kesalahan prediksi paling banyak terjadi pada batas antara kelas Lancar dan Perhatian, yang secara intuitif masuk akal mengingat kedua kelas tersebut memiliki karakteristik yang saling berdekatan.

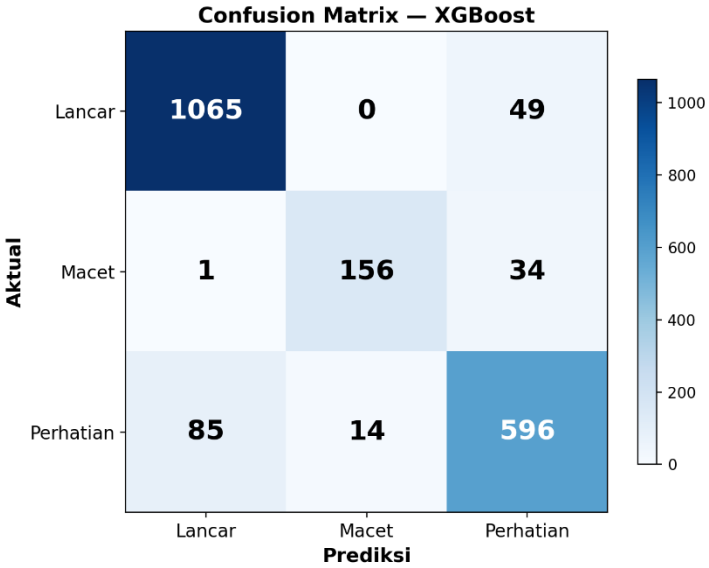

Gambar 8. Confusion matrix model XGBoost pada test set

4.3 Analisis Feature Importance

Analisis feature importance berdasarkan metrik gain dari model XGBoost (Gambar 9) mengungkapkan bahwa Debt-to-Income Ratio (DTI) merupakan fitur paling berpengaruh dengan kontribusi sebesar 21,79%. Fitur ini menunjukkan betapa pentingnya rasio beban utang terhadap pendapatan dalam memprediksi risiko kredit. Hari Tunggakan Terlama menempati posisi kedua (16,74%), diikuti oleh Jumlah Tunggakan (9,24%) dan Riwayat Kredit (6,89%). Rangkuman sepuluh fitur teratas disajikan dalam Tabel 5.

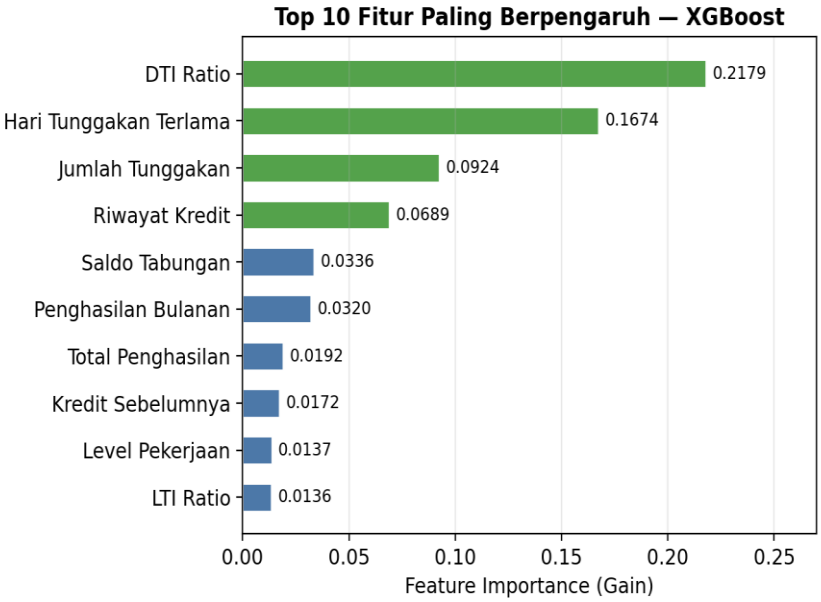

Gambar 9. Top 10 fitur paling berpengaruh berdasarkan feature importance XGBoost
Tabel 5. Sepuluh Fitur Paling Berpengaruh (XGBoost Feature Importance)

Rank	Fitur	Importance	Interpretasi
1	DTI Ratio	0,2179	Beban utang relatif terhadap pendapatan
2	Hari Tunggakan Terlama	0,1674	Indikator langsung riwayat keterlambatan
3	Jumlah Tunggakan	0,0924	Frekuensi keterlambatan pembayaran
4	Riwayat Kredit	0,0689	Rekam jejak kepatuhan pembayaran
5	Saldo Tabungan	0,0336	Cadangan likuiditas nasabah
6	Penghasilan Bulanan	0,0320	Kapasitas pembayaran
7	Total Penghasilan	0,0192	Pendapatan komprehensif
8	Kredit Sebelumnya	0,0172	Pengalaman kredit
9	Level Pekerjaan	0,0137	Stabilitas dan level karir
10	LTI Ratio	0,0136	Rasio pinjaman terhadap pendapatan

Temuan ini menunjukkan bahwa faktor-faktor terkait perilaku pembayaran historis (tunggakan, riwayat kredit) dan rasio keuangan (DTI, LTI) memiliki daya prediksi yang jauh lebih tinggi dibandingkan faktor demografis seperti usia, jenis

kelamin, atau status pernikahan. Implikasi praktisnya adalah bahwa lembaga keuangan sebaiknya memprioritaskan pengumpulan dan verifikasi data riwayat kredit dan rasio keuangan dalam proses evaluasi kredit.

4.4 Diskusi

Hasil benchmarking menunjukkan keunggulan XGBoost pada mayoritas metrik evaluasi, meskipun selisih performa antar model relatif kecil dan Random Forest justru unggul pada Precision-Macro. Beberapa faktor yang berkontribusi terhadap keunggulan XGBoost dapat diidentifikasi. Pertama, mekanisme gradient boosting memungkinkan XGBoost secara iteratif memperbaiki prediksi pada sampel-sampel yang sulit diklasifikasikan, terutama pada batas keputusan antara kelas Lancar dan Perhatian. Kedua, regularisasi L1 dan L2 bawaan efektif mencegah overfitting, sebagaimana terlihat dari konvergensi early stopping pada iterasi ke-172. Ketiga, kemampuan XGBoost dalam menangkap interaksi nonlinier antar fitur memberikan keunggulan dibandingkan Logistic Regression yang terbatas pada hubungan linear.

Perlu dicatat bahwa Logistic Regression memberikan performa yang sangat kompetitif (akurasi identik 0,9085) dengan waktu pelatihan yang jauh lebih cepat (0,3 detik). Hal ini mengindikasikan bahwa untuk skenario di mana interpretabilitas dan kecepatan menjadi prioritas utama, Logistic Regression tetap menjadi pilihan yang layak dipertimbangkan. Random Forest, meskipun memiliki Accuracy dan F1-Macro sedikit di bawah kedua model lainnya, justru mencatat Precision-Macro tertinggi (0,9146), yang menunjukkan bahwa model ini sangat selektif dalam memberikan prediksi positif. Pembatasan max_depth=8 kemungkinan membatasi recall namun meningkatkan presisi prediksi.

5. Kesimpulan dan Saran

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan yang telah diuraikan, dapat ditarik kesimpulan sebagai berikut:

Pertama, ketiga algoritma machine learning yang diuji (Logistic Regression, Random Forest, dan XGBoost) menunjukkan performa yang baik dalam klasifikasi risiko kredit tiga kelas dengan akurasi di atas 90%. Hal ini mengonfirmasi efektivitas pendekatan machine learning dalam sistem penilaian kredit.

Kedua, XGBoost memberikan performa terbaik pada metrik Accuracy (0,9085), F1-Macro (0,8907), dan Recall-Macro (0,8768), meskipun Random Forest unggul pada Precision-Macro (0,9146). Keunggulan XGBoost terutama terlihat pada metrik F1-Macro yang merupakan keseimbangan antara precision dan recall, mengindikasikan kemampuan yang lebih baik dalam menangani klasifikasi multiclass dengan distribusi kelas tidak seimbang.

Ketiga, analisis feature importance mengungkapkan bahwa DTI Ratio (21,79%), Hari Tunggakan Terlama (16,74%), dan Jumlah Tunggakan (9,24%) merupakan tiga fitur paling prediktif. Temuan ini menegaskan bahwa indikator perilaku pembayaran dan rasio keuangan merupakan faktor kunci dalam penilaian risiko kredit.

5.2 Saran

Untuk pengembangan penelitian selanjutnya, disarankan: (1) melakukan validasi dengan data kredit riil dari lembaga keuangan untuk memverifikasi generalisasi temuan; (2) mengeksplorasi teknik penanganan imbalanced class seperti SMOTE atau class weighting untuk meningkatkan performa pada kelas Macet; (3) menambahkan algoritma pembanding seperti LightGBM, CatBoost, atau neural network; (4) melakukan hyperparameter tuning menggunakan grid search atau Bayesian optimization untuk memaksimalkan performa setiap model; serta (5) mengimplementasikan model dalam bentuk API atau dashboard interaktif untuk evaluasi kredit secara real-time.

Daftar Pustaka

[1] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.

[2] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

[3] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression*. 3rd ed. Hoboken: John Wiley & Sons.

[4] Hand, D. J., & Henley, W. E. (1997). Statistical Classification Methods in Consumer Credit Scoring: A Review. *Journal of the Royal Statistical Society: Series A*, 160(3), 523-541.

[5] Lessmann, S., et al. (2015). Benchmarking State-of-the-Art Classification Algorithms for Credit Scoring: An Update of Research. *European Journal of Operational Research*, 247(1), 124-136.

[6] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

[7] Otoritas Jasa Keuangan. (2024). *Statistik Perbankan Indonesia*. Jakarta: OJK.

[8] Xia, Y., et al. (2017). A Boosted Decision Tree Approach Using Bayesian Hyper-parameter Optimization for Credit Scoring. *Expert Systems with Applications*, 78, 225-241.

[9] Brown, I., & Mues, C. (2012). An Experimental Comparison of Classification Algorithms for Imbalanced Credit Scoring Data Sets. *Expert Systems with Applications*, 39(3), 3446-3453.

[10] Thomas, L. C. (2009). *Consumer Credit Models: Pricing, Profit and Portfolios*. Oxford University Press.